



EACH

UNIVERSIDADE DE SÃO PAULO
ESCOLA DE ARTES, CIÊNCIAS E HUMANIDADES
GRADUAÇÃO EM SISTEMAS DE INFORMAÇÃO

HENRIQUE COSTA DIONÍSIO

Plano de Atividades de PSG

Avaliação de Variabilidade em Large Language Models por meio de Digital Twins Conversacionais

**São Paulo
2026**

HENRIQUE COSTA DIONÍSIO

**Avaliação de Variabilidade em Large Language Models por meio
de Digital Twins Conversacionais**

Plano de atividades apresentado como parte
dos requisitos necessários para cumprimento
da disciplina ACH2018 – Projeto
Supervisionado ou de Graduação II.

Orientadora: Profa. Dra. Sarajane Marques
Peres

**São Paulo
2026**

Resumo:

Grandes modelos de linguagem (*Large Language Models* - LLMs) como GPT e LLaMA apresentam natureza estocástica: pequenas mudanças de decodificação ou de instrução podem alterar trajetórias de resposta, comprometendo a confiabilidade de suas respostas em aplicações críticas. Este projeto avalia sistematicamente o impacto dos parâmetros *temperature*, *top-p* e turno do *fork* na variabilidade das respostas utilizando *Digital Twins* conversacionais. Utilizando um protótipo de *fork* controlado já desenvolvido, o trabalho focará na validação empírica através de experimentação *Grid Search* tridimensional. Serão definidas métricas qualitativas (factualidade, adequação institucional, robustez) para análise comparativa das respostas em diferentes momentos de conversas *multi-turno*. Os resultados esperados incluem *dataset* estruturado de respostas comparativas, recomendações de configuração de parâmetros para diferentes contextos de uso e validação metodológica da abordagem de *Digital Twin* para avaliação de LLMs, contribuindo para o uso mais responsável desses modelos em aplicações reais.

Palavras Chaves

- *Large Language Models*
- *Digital Twins*
- Monitoramento de Sistemas de IA generativa
- Avaliação de Sistemas de IA generativa
- Experimentação Controlada

Modalidade:

- (X) Trabalho de Graduação Curto – 1 semestre - individual
- () Trabalho de Graduação Longo (parte 1) – 1 ano – individual
- () Trabalho de Graduação Longo (parte 2) – 1 ano - individual
- () Trabalho de Graduação Curto – 1 semestre – grupo
- () Trabalho de Graduação Longo (parte 1) – 1 ano – grupo
- () Trabalho de Graduação Longo (parte 2) – 1 ano – grupo

1 Apresentação do problema

Grandes modelos de linguagem (*Large Language Models* - LLMs) como GPT, LLaMA e Gemini estão sendo adotados em aplicações produtivas: *chatbots*, assistentes de código, análise de documentos e suporte à decisão. A adoção em domínios críticos, como financeiro, jurídico, educacional e de saúde, amplia o impacto de suas respostas, tornando essencial a adoção de mecanismos robustos de monitoramento e avaliação.

Um desafio central é a natureza estocástica desses modelos. A mesma pergunta pode gerar respostas significativamente diferentes dependendo dos parâmetros de decodificação utilizados, especialmente *temperature* e *top-p*. Esses parâmetros controlam o nível de aleatoriedade na geração de *tokens*, influenciando diretamente a criatividade, consistência e factualidade das respostas. Contudo, existe uma lacuna científica quanto à avaliação sistemática e controlada do impacto desses parâmetros na qualidade e robustez das respostas em diferentes contextos de uso.

Os métodos de avaliação predominantes usam *benchmarks* laboratoriais estáticos, insuficientes para capturar riscos e limitações que emergem em uso real. A lacuna entre avaliação laboratorial e desempenho em produção compromete a confiabilidade dos sistemas baseados em LLMs, dificultando a detecção de erros factuais, vieses contextuais e falhas de consistência.

Nesse contexto, a aplicação do paradigma de gêmeos digitais (*Digital Twins*) oferece uma abordagem promissora. O conceito consiste na criação de uma cópia computacional de um sistema real, capaz de reproduzir seu comportamento para fins de monitoramento, diagnóstico e simulação. Originalmente empregado em sistemas ciberfísicos e engenharia de manufatura (GRIEVES, 2019; FULLER et al., 2020), o uso de *Digital Twins* para avaliação de LLMs ainda é incipiente. Estudos recentes exploram o uso de LLMs como elementos internos de *Digital Twins* para simulação de ambientes (XIA et al., 2024; YANG et al., 2025), mas há um vazio quanto à aplicação do gêmeo como observador de interações reais com LLMs em produção.

Este projeto utilizará um protótipo de *Digital Twin* para LLMs desenvolvido experimentalmente, baseado no conceito de *fork* controlado de contextos conversacionais. O

protótipo permite duplicar um diálogo em qualquer ponto da história e aplicar variações sistemáticas de parâmetros sem interferir no funcionamento do sistema original. Este trabalho tem caráter de validação metodológica: caso a abordagem se mostre eficaz, o sistema será posteriormente integrado como módulo oficial ao sistema HarpIA. Com essa base técnica disponível, o projeto focará na validação empírica através de experimentação *Grid Search* tridimensional, avaliando sistematicamente o impacto dos parâmetros *temperature*, *top-p* e turno do *fork* na variabilidade das respostas de LLMs. A relevância está em fornecer evidências empíricas para uso mais responsável de LLMs em aplicações críticas e validar a viabilidade da abordagem de *Digital Twin* para este fim.

2 Objetivos

O objetivo geral deste trabalho é avaliar sistematicamente o impacto dos parâmetros *temperature*, *top-p* e turno do *fork* na variabilidade das respostas de grandes modelos de linguagem (LLMs) utilizando a abordagem de *Digital Twins* conversacionais com *fork* controlado.

Como objetivos específicos, este projeto pretende:

- Definir e formalizar um conjunto de métricas qualitativas para análise de factualidade, adequação institucional e robustez das respostas geradas por LLMs.
- Conduzir experimentação controlada com *Grid Search* tridimensional de *temperature* $\in \{0.0, 0.4, 0.7, 1.0\}$, *top-p* $\in \{0.0, 0.4, 0.7, 1.0\}$ e diferentes turnos de *fork* sobre um conjunto diversificado de conversas de teste.
- Analisar comparativamente os padrões de variabilidade nas respostas geradas pelos *twins* digitais, identificando relações entre configurações de parâmetros, turnos de *fork* e características das respostas.
- Identificar configurações de parâmetros e momentos de *fork* mais adequados para diferentes contextos de uso, fornecendo recomendações baseadas em evidências empíricas.

3 Materiais e métodos

Este projeto adota uma abordagem de pesquisa aplicada, experimental, com objetivos descritivos e explicativos. A caracterização metodológica envolve uma abordagem quali-quantitativa, com procedimentos experimentais e método de avaliação baseado em análise qualitativa de conteúdo das respostas geradas pelos LLMs.

Infraestrutura técnica

A infraestrutura necessária para execução deste projeto já está parcialmente implementada. O protótipo experimental consiste em uma API desenvolvida em Python 3.12 utilizando FastAPI como *framework* web, SQLAlchemy para modelagem de dados e SQLite como banco de dados. A integração com LLMs é realizada através da biblioteca LangChain, permitindo comunicação com diferentes provedores de modelos de IA generativa. Um cliente CLI (*Command Line Interface*) desenvolvido com a biblioteca Rich permite a interação com o sistema. A escolha do modelo específico (aberto ou proprietário) dependerá da disponibilidade de controle sobre os parâmetros *temperature* e *top-p*, priorizando modelos que permitam ajuste fino desses parâmetros.

O diferencial desta implementação é a capacidade de realizar *fork* em qualquer ponto da história do diálogo. Ao disparar um gêmeo, o sistema permite aplicar perturbações controladas: variação de parâmetros técnicos (*temperature* e *top-p*) e injeção de instruções de sistema ou ataques de *prompt*. O *twin* com os mesmos parâmetros do modelo real serve como *baseline* para comparações, enquanto os demais *twins* exploram configurações alternativas.

Protocolo experimental

O protocolo experimental consiste em uma experimentação *Grid Search* com as seguintes características:

- **Grade de parâmetros tridimensional:** Serão geradas combinações baseadas em três dimensões: (1) *temperature* $\in \{0.0, 0.4, 0.7, 1.0\}$, (2) *top-p* $\in \{0.0, 0.4, 0.7, 1.0\}$ e (3) turno do *fork*. Para cada conversa de teste, o *fork* será realizado em quatro momentos distintos ao longo da conversa (exemplo: turnos

1, 3, 5 e 7 de uma conversa de 8 turnos), resultando em uma exploração sistemática do espaço de parâmetros considerando também o contexto conversacional acumulado.

- ***Twin baseline***: Além das combinações experimentais, será implementado um *twin baseline* para cada turno de *fork* com os mesmos parâmetros do modelo real (geralmente temperature 0.7 e top-p 1.0), servindo como linha de base para comparações. Este gêmeo de controle é essencial para quantificar a variação natural do modelo.
- **Conjunto de *prompts* de teste**: Conjunto de conversas de teste: Serão elaboradas de 3 a 5 conversas multi-turno (cada uma com 7-10 turnos) cobrindo diferentes categorias: diálogos factuais (que exigem precisão e acumulação de informações), diálogos criativos (que permitem maior liberdade e exploração), diálogos instrucionais (que exigem conformidade com diretrizes ao longo da interação) e diálogos contextuais específicos do domínio. O histórico conversacional é essencial, pois permite avaliar como a variabilidade se manifesta considerando o contexto acumulado.
- **Procedimento experimental**: Para cada conversa de teste, será criado um diálogo original até determinado turno. Nesse ponto, será realizado um *fork*, disparando múltiplos *twins* com diferentes combinações de *temperature* e *top-p*. O mesmo procedimento será repetido em diferentes turnos da mesma conversa (ex: turnos 1, 3, 5, 7), permitindo observar como o contexto conversacional acumulado interage com os parâmetros de decodificação. Cada *twin* continuará a conversa a partir do ponto de *fork*, e todas as respostas serão coletadas e armazenadas de forma estruturada no banco de dados.
- **Análise qualitativa comparativa**: As respostas dos *twins* serão analisadas comparativamente utilizando as métricas qualitativas definidas. A análise buscará identificar padrões de variabilidade, relações entre configurações de parâmetros e características das respostas, além de configurações mais adequadas para diferentes contextos.

Métricas de análise

As métricas de análise qualitativa a serem definidas e formalizadas incluem:

- **Factualidade:** Avaliação da precisão e veracidade das informações apresentadas nas respostas, identificando alucinações, erros factuais ou inconsistências.
- **Adequação institucional:** Análise da conformidade das respostas com diretrizes institucionais, contextualização adequada e alinhamento com valores e políticas da aplicação.
- **Robustez:** Medição da consistência e estabilidade das respostas frente a variações de parâmetros, identificando configurações que geram respostas mais previsíveis ou mais variadas.
- **Criatividade *versus* repetitividade:** Avaliação do equilíbrio entre respostas criativas/originais e respostas genéricas/repetitivas, relacionando com os valores de *temperature* e *top-p* utilizados.

O sistema de métricas será implementado de forma modular, permitindo extensões futuras. A análise poderá incluir tanto avaliação humana assistida quanto uso de modelos de linguagem para análise automática de aspectos específicos. Como extensão futura, caso sejam utilizados modelos abertos, a análise poderá incorporar a avaliação dos *logits* de predição, permitindo compreender melhor o comportamento probabilístico do modelo durante a geração.

Tecnologias

As tecnologias utilizadas no projeto são: Python 3.12, FastAPI (*framework* web), SQLAlchemy (*ORM* - *Object-Relational Mapping*), SQLite (banco de dados), LangChain (integração com LLMs), modelo LLM a ser definido (aberto ou proprietário, dependendo de controle sobre parâmetros), Rich (interface CLI) e bibliotecas auxiliares de análise de dados (*pandas*, *matplotlib*).

4 Resultados esperados

Os resultados esperados deste projeto estão organizados em artefatos práticos, contribuições científicas e impactos esperados.

Artefatos práticos

- **Dataset estruturado de respostas comparativas:** Conjunto de dados contendo as respostas geradas pelas combinações de parâmetros (*temperature* $\times$ *top-p*) em diferentes turnos de *fork* para cada uma das 3 a 5 conversas de teste. Considerando 16 combinações por turno, 4 turnos de *fork* por conversa, e 3-5 conversas, o volume estimado é de aproximadamente 192 a 320 respostas distintas por conversa completa. Este *dataset* será armazenado de forma estruturada no banco de dados SQLite e disponibilizado de forma anonimizada para futuras análises.
- **Conjunto formalizado de métricas qualitativas:** Definição clara e documentada das métricas de factualidade, adequação institucional, robustez e criatividade *versus* repetitividade, com critérios de avaliação, escalas e procedimentos de aplicação.
- **Relatórios experimentais com análise comparativa:** Documentos estruturados apresentando a análise qualitativa das respostas geradas, comparando os padrões de variabilidade observados entre diferentes configurações de parâmetros e turnos de *fork*.
- **Tabelas e gráficos comparativos de variabilidade:** Visualizações que sintetizem os resultados observados, facilitando a identificação de padrões e relações entre parâmetros, turnos de *fork* e características das respostas.

Contribuições científicas

- **Documentação empírica do impacto de *temperature*, *top-p* e turno do *fork*:** Evidências sistemáticas sobre como esses parâmetros influenciam a qualidade, consistência e adequação das respostas de LLMs em diferentes contextos de uso e momentos da conversa.
- **Recomendações de configuração de parâmetros:** Diretrizes baseadas em evidências sobre quais configurações são mais adequadas para diferentes categorias de diálogos (factuais, criativos, instrucionais, contextuais) e em diferentes momentos da conversa.

- **Validação da abordagem de *Digital Twin* para avaliação de LLMs:** Demonstração prática da viabilidade e utilidade do paradigma de gêmeos digitais para avaliação observacional, não intrusiva e auditável de modelos generativos em uso real.

Impactos esperados

- Contribuir para o uso mais responsável e consciente de LLMs em aplicações reais, especialmente em domínios críticos que exigem alta confiabilidade.
- Fornecer base metodológica para futuras extensões da abordagem, incluindo simulação longitudinal (acompanhamento de conversas *multi-turno* estendidas), experimentação com múltiplos modelos (ex.: GPT, LLaMA, Gemini) e intervenção automática (ajuste dinâmico de parâmetros).
- Ampliar a compreensão científica sobre a natureza estocástica dos LLMs e suas implicações práticas para o *design* de sistemas de informação.

5 Cronograma

O cronograma abaixo detalha a distribuição temporal das atividades do projeto ao longo do semestre letivo de 2026, considerando as datas oficiais de entrega do plano de atividades (março), apresentação de andamento (maio) e entrega do trabalho monográfico (junho).

Tabela 1: Cronograma de atividades (para trabalho semestral – apagar se for trabalho anual)

	março		abril		maio		junho	
Atividades / Quinzenas	1	2	1	2	1	2	1	2
Entrega do plano de atividades		X						
Revisão bibliográfica complementar			X					
Definição e formalização das métricas qualitativas			X	X				
Refinamento do ambiente experimental				X				
Elaboração do conjunto de conversas de teste				X				
Execução dos experimentos <i>Grid Search</i>					X			
Apresentação de andamento					X			
Análise qualitativa dos resultados					X	X		

Escrita da monografia	X	X
Revisão e ajustes finais	X	
Entrega do trabalho monográfico		X

Referências bibliográficas

BOMMASANI, R. et al. On the opportunities and risks of foundation models. *arXiv preprint arXiv:2108.07258*, 2021.

BROWN, T. B. et al. Language models are few-shot learners. In: *Advances in Neural Information Processing Systems*, v. 33, p. 1877-1901, 2020.

CHANG, Y. et al. A survey on evaluation of large language models. *ACM Transactions on Intelligent Systems and Technology*, v. 15, n. 3, mar. 2024.

DEVLIN, J. et al. BERT: Pre-training of deep bidirectional transformers for language understanding. In: *Proceedings of NAACL-HLT*, 2019. *Anais [...]*. p. 4171-4186.

FULLER, A.; FAN, Z.; DAY, C.; BARLOW, C. Digital twin: Enabling technologies, challenges and open research. *IEEE Access*, v. 8, p. 108952-108971, 2020.

GRIEVES, M. Virtually intelligent product systems: Digital and physical twins. In: *Complex Systems Engineering: Theory and Practice*. p. 175-200. Wiley, 2019.

HOLZINGER, A. et al. Information fusion as an integrative cross-cutting enabler to achieve robust, explainable, and trustworthy medical artificial intelligence. *Information Fusion*, v. 79, p. 263-278, 2022.

OUYANG, L. et al. Training language models to follow instructions with human feedback. In: *Advances in Neural Information Processing Systems*, v. 35, p. 27730-27744, 2022.

VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems*, v. 30, 2017.

XIA, Y. et al. Llm experiments with simulation: Large language model multi-agent system for simulation model parametrization in digital twins. In: 2024 IEEE 20TH INTERNATIONAL

CONFERENCE ON EMERGING TECHNOLOGIES AND FACTORY AUTOMATION (ETFa), 2024. *Anais [...]*. IEEE, 2024. p. 1-4.

YANG, L.; LUO, S.; CHENG, X.; YU, L. Leveraging large language models for enhanced digital twin modeling: Trends, methods, and challenges. *arXiv preprint arXiv:2503.02167*, 2025.

YAO, Y.; ZHANG, C.; WANG, Z. A survey on large language model (llm) security and privacy: The good, the bad, and the ugly. *High-Confidence Computing*, v. 4, n. 2, 2024.

ZHAO, W. X. et al. A survey of large language models. *arXiv preprint arXiv:2303.18223*, 2023.