

links úteis:

1. <https://platform.openai.com/settings/organization/limits>

16/04: reunião de andamento (primeira)

RAG: recuperador de documento. É uma consulta externa que a IA faz em bases de dados e complementa ao modelo para responder à pergunta.

É “gêmeo digital” porque é um sistema dentro de um simulador, que é o mais próximo de uma situação real possível. Uma possível grande crítica é isso ser um simulador e não um usuário real.

Como vou avaliar se o resultado que chegou é melhor ou pior do que os outros?

- Gastou mais ou menos tokens pra chegar na solução?
- O que?
- Pode ser uma caixinha que eu troco, coloco o método de avaliação e isso é validado. Ou então contagem de troca de mensagens (ex: se foi longo usuário não vai preferir). Ou se a conversa final chegou numa resolução ou não. LLM as a Judge. Análise de qualidade (com parâmetros).

exemplo: usuário tá trocando mensagem, modelo manda mensagem e responde (troca de 10 mensagens, conversa real). Daí pega essa conversa real e transforma num teste para alterações nos parâmetros pra verificar como o sistema se desenrola, se é igual ou diferente, melhor ou pior. Daí faz testes com pedaços menores a maiores (3 primeiras, 4, 5, ...). Se o que foi alterado melhorou o sistema, o “parafuso” que acertou pode substituir o sistema em produção.

“Problema gravíssimo na lógica”: conversa real tinha pessoa conversando. conversa do gêmeo digital não vai ter pessoa conversando.

- Precisa de um LLM que imita o usuário (ponto delicado)

Não é um projeto para ser finalizado no TCC. Mas é pra dar um start.

1. medida de qualidade
2. conjunto de conversas (o ideal seria ter +200 usuários, mas não vai dar)
3. algo adicional que a gente altere
 - a. temperatura, top-p, top-k, ...: talvez isso não tenha tanto impacto numa conversa.
 - b. engenharia de prompt: boa pedida, onde se sai melhor. Testar um com engenharia de prompt simples, mediana e complexa. - exemplo: documentos de [AGENTS.md](#) no projeto é bom ou ruim?
 - c. POC: estudar infraestrutura e ver o que é preciso pra fazer um experimento com meia dúzia de conversas - 10 a 15 trocas (se não colocar ponto de parada conversam indefinidamente - cuidar com limite de créditos); e dois

gêmeos por exemplo - um que muda parametro, outro que melhora/piora a engenharia de prompts. E validar a troca de tokens / trocas de mensagem. É bom ter o gêmeo identico também (grupo controle).

- d. ver o que é preciso para rodar o que é necessário e rodar infraestrutura/desenhar o experimento e rodar o experimento.
- e. fazer análise crítica do experimento e já seria o TCC.
- f. Depois de finalizar essa POC e finalizar o TCC. Se fechar rápido dá pra continuar evoluindo, mas não é a expectativa final. Se for experimento em escala precisa de um valor maior. Daí precisa justificar, por isso nesse TCC talvez não funcione.

fazer planejamento:

- o que tenho que fazer para o TCC
- distribuir daqui até o dia de entrega do TCC
- a cada semana vou dizer o que tive de andamento e fazer o check
- vai me mandar às 12h de amanhã a questão das APIs.

reunião curta dia 14/05/2026 (15 minutos):

- posso usar o digital twins para testar prompts
- mas vou publicar os prompts do twin: não pode ser segredo do produto - opgithub ou texto ou algum lugar
- não serão grandes experimentos, sem gastar muitos dólares - existe limitação no perfil - mas é um dinheiro FAPESP - tem que ser associado ao projeto FAPESP
- 10 dólares para testes
- se precisar de mais vou pedindo limites
- vendo como vai sendo os gastos
- posso ver
- focar na escrita do TCC
 - texto precisa ser claro
- receio com o que vai acontecer quando acabar a paralização dos alunos - estou fazendo 5 disciplinas, não sei se professores vão correr com as coisas - ninguém sabe o que vai acontecer
- adiantar o máximo possível agora

Se não der certo algo, posso passar alguma dúvida ou discussão no whatsapp ou marcar reunião adicional. Preciso falar com a profa e ela me avisa. Tempo com antecedência de preferência.